

# 线性代数方程组

浙江大学控制学院

# 本章内容

- 高斯消去法
- LU分解、特殊矩阵和矩阵求逆
- 误差分析、条件数
- 迭代方法

# 误差分析和方程组条件数

- 利用逆矩阵确定方程组是否病态的方法
  - 缩放系数矩阵 $A$ ，使其每一行的最大元素为1。计算缩放后的逆矩阵，如果 $A^{-1}$ 中有元素的值大于1几倍，则方程组是病态的。
  - 将逆矩阵与原矩阵相乘，检查结果是否接近1。如果不接近1，则方程组是病态的。
  - 求逆矩阵的逆矩阵，与原系数矩阵对比。如果不相等，则方程组是病态的。

# 向量和矩阵的范数

- 向量的范数

- 三维欧氏空间中向量长度概念的推广
- 定义

设对任意向量  $x \in R^n$ , 按一定的规则有一实数与之对应, 记为  $\|x\|$ , 若  $\|x\|$  满足

1,  $\|x\| \geq 0$ , 且  $\|x\| = 0$  当且仅当  $x = 0$ ; (正定)

2,  $\|\alpha x\| = |\alpha| \cdot \|x\|$ ,  $\alpha$  为任意实数 (齐次)

3,  $\|x + y\| \leq \|x\| + \|y\|$ , 对任意  $x, y \in R^n$

(三角不等式)

则称  $\|x\|$  为 向量  $x$  的范数

# 向量和矩阵的范数

- 几种向量范数

- 向量的“2”范数  
(欧几里德范数)

$$\|x\|_2 = \sqrt{x_1^2 + \cdots + x_n^2} = \left( \sum_{i=1}^n x_i^2 \right)^{1/2}$$

- 向量的“1”范数

$$\|x\|_1 = |x_1| + \cdots + |x_n| = \sum_{i=1}^n |x_i|$$

- 向量的“ $\infty$ ”范数  
(极大值范数或一致向量范数)

$$\|x\|_\infty = \max \{|x_1|, \cdots, |x_n|\} = \max_{1 \leq i \leq n} \{|x_i|\}$$

- 向量的“ $p$ ”范数

$$\|x\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}$$

# 向量和矩阵的范数

## ● 矩阵的范数

定义：对任意 $n$ 阶方阵 $A$ ，按一定的规则有一实数与之对应，记为 $\|A\|$ 。若 $\|A\|$ 满足：

- 1  $\|A\| \geq 0$ ，且 $\|A\| = 0$ 当且仅当 $A = 0$ ；（正定）
- 2  $\|\alpha A\| = |\alpha| \cdot \|A\|$ ， $\alpha$ 为任意实数；（齐次）
- 3  $\|A + B\| \leq \|A\| + \|B\|$ ，对任意 $A, B$ 两个 $n$ 阶方阵；（三角不等式）
- 4  $\|AB\| \leq \|A\| \|B\|$ ；（矩阵乘法不等式，相容性条件）

则称 $\|A\|$ 为矩阵 $A$ 的范数

# 向量和矩阵的范数

- 几种矩阵范数

- 矩阵的“2”范数  
(谱范数)

$$\|A\|_2 = \left[ \lambda_{\max}(A^T A) \right]^{1/2}$$

- 矩阵的“1”范数  
(列和范数)

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

- 矩阵的“ $\infty$ ”范数  
(行和范数)

$$\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

# 向量和矩阵的范数

- 谱和谱半径

- $A \in R^{n \times n}$  的特征值为  $\lambda_1, \lambda_2, \dots, \lambda_n$ ,
- 称  $A$  的所有特征值的集合为  $A$  的谱
- 称  $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$  为  $A$  的谱半径

- $\|A\|$  为  $A$  的任意一种范数, 有  $\rho(A) \leq \|A\|$

- (按行) 严格对角占优阵

- 如果  $A$  满足条件  $|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \quad (i = 1, 2, \dots, n)$

即  $A$  的每一行对角元素的绝对值都严格大于同行其他元素绝对值之和



# 病态方程组和矩阵条件数

- 例: 
$$\begin{bmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.99 \\ 1.97 \end{bmatrix} \quad x = (1, 1)^T$$

- 若系数矩阵有微小扰动 
$$\Delta A = \begin{bmatrix} 0.0001 & 0 \\ 0 & 0 \end{bmatrix}$$

$$\frac{\|\Delta A\|_{\infty}}{\|A\|_{\infty}} = 5 \times 10^{-5}$$

- 则 
$$\begin{bmatrix} 1.0001 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.99 \\ 1.97 \end{bmatrix} \Rightarrow \tilde{x}^{(1)} = (50, -48.5)^T$$

$$\frac{\|\Delta x^{(1)}\|_{\infty}}{\|x\|_{\infty}} = 49.5$$

- 若右端有微小扰动

$$\Delta b = \begin{bmatrix} -0.0001 \\ 0.0001 \end{bmatrix}$$

$$\frac{\|\Delta b\|_{\infty}}{\|b\|_{\infty}} = 5 \times 10^{-5}$$

- 则 
$$\begin{bmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.9899 \\ 1.9701 \end{bmatrix} \Rightarrow \tilde{x}^{(2)} = (2.97, -0.99)^T$$

$$\frac{\|\Delta x^{(2)}\|_{\infty}}{\|x\|_{\infty}} = 1.99$$

- 若同时对系数矩阵和右端有扰动, 则

$$\begin{bmatrix} 1.0001 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.9899 \\ 1.9701 \end{bmatrix} \Rightarrow \tilde{x}^{(3)} = (148.5, -148.005)^T$$

$$\frac{\|\Delta x^{(3)}\|_{\infty}}{\|x\|_{\infty}} = 149.005$$

# 病态方程组和矩阵条件数

- 扰动方程  $(A + \Delta A)x = b + \Delta b$
- 如果方程组的系数或常数项有微小改变时，解会发生很大的改变，则称这种方程组为“**病态**”的
- 扰动方程的解与原方程的解相对误差不大，称为**良态**方程
- 方程组的“**条件**”问题
- 一般说来，在用计算机解方程组时，实际上解的都是扰动方程，这是由于计算过程中不可避免地会产生舍入误差
- 对于良态问题，只要数值方法是稳定的，就可以得到较好的结果
- 而对于病态问题，即使算法是稳定的，其计算结果有时也会很坏

# 扰动方程组的误差界

$$\|AB\| \leq \|A\| \|B\|$$

- $b$  的扰动

$$A(x + \Delta x) = b + \Delta b \Rightarrow \Delta x = A^{-1} \Delta b$$

$$\Downarrow$$

$$\|\Delta x\| \leq \|A^{-1}\| \|\Delta b\|$$

$$\|b\| = \|Ax\| \leq \|A\| \|x\| \Rightarrow \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$$

$$\left. \begin{array}{l} \|\Delta x\| \leq \|A^{-1}\| \|\Delta b\| \\ \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|} \end{array} \right\} \Rightarrow \frac{\|\Delta x\|}{\|x\|} \leq \|A\| \|A^{-1}\| \frac{\|\Delta b\|}{\|b\|}$$

- $A$  的扰动

$$(A + \Delta A)(x + \Delta x) = b \Rightarrow \Delta x = -A^{-1} \Delta A (x + \Delta x) \Rightarrow \frac{\|\Delta x\|}{\|x + \Delta x\|} \leq \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}$$

- 同时扰动

$$(A + \Delta A)(x + \Delta x) = b + \Delta b \Rightarrow \Delta x = (A + \Delta A)^{-1} (\Delta b - \Delta A x)$$

$$\text{由恒等式 } (A + \Delta A)^{-1} = A^{-1} (I + \Delta A A^{-1})^{-1} \Rightarrow \Delta x = A^{-1} [I + \Delta A A^{-1}]^{-1} (\Delta b - \Delta A x)$$

$$\text{假设 } \|A^{-1}\| \|\Delta A\| \leq 1$$

$$\Downarrow \quad \|b\| \leq \|A\| \|x\|$$

$$\text{则 } \|A^{-1} [I + \Delta A A^{-1}]^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|\Delta A\| \|A^{-1}\|} \Rightarrow \frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}} \left( \frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right)$$

# 病态方程组和矩阵条件数

- 条件数

- 设  $A \in R^{n \times n}$ , 非奇异,  $\text{Cond}(A) = \|A\| \|A^{-1}\|$

- $K(A) = \|A\|_2 \|A^{-1}\|_2$  称为谱条件数

- 条件数的性质

- 对任何非奇异矩阵  $A$ , 有  $\text{Cond}(A) \geq 1$ 。

- 对任何非奇异矩阵  $A$ , 非零常数  $c$ , 有  $\text{Cond}(cA) = \text{Cond}(A)$

- 若  $P$  为正交矩阵, 则  $K(P) = 1$ , 且  $K(PA) = K(AP) = K(A)$

- 若  $A = A^T$ ,  $K(A) = \frac{|\lambda_{\max}(A)|}{|\lambda_{\min}(A)|}$

# 病态方程组和矩阵条件数

- 线性方程组 $Ax=b$ 解的相对误差直接与 $A$ 的条件数相关
- $A$ 的条件数 $\text{Cond}(A)$ 相对大( $\gg 1$ ), 称 $Ax=b$ 是病态方程组/坏条件, 或 $A$ 是病态的; 当 $A$ 的条件数 $\text{Cond}(A)$ 相对小, 称 $Ax=b$ 是良态方程组/好条件, 或 $A$ 是良态的。

$$A = \begin{bmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{bmatrix}$$

$$\text{cond}(A)_2 = K(A) = \frac{|\lambda_{\max}|}{|\lambda_{\min}|} = \frac{1.98005}{0.00005} = 39206 \gg 1$$

方程是病态方程

# 矩阵条件数

- Hilbert矩阵是一个著名的病态矩阵，它是一个对称正定矩阵，当  $n \geq 3$  时，Hilbert矩阵是病态矩阵
- $n$  越大，条件数越大
- Matlab 中 `hilb()` 构造 hilbert 矩阵，`invhilb()` 可求精确逆

$$A = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \dots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \dots & \frac{1}{n+1} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \dots & \frac{1}{n+2} \\ \dots & \dots & \dots & \dots & \dots \\ \frac{1}{n} & \frac{1}{n+1} & \frac{1}{n+2} & \dots & \frac{1}{2n-1} \end{bmatrix}$$

# 相对误差的事后估计 (近似解可靠性判别)

- 设 $Ax=b$ ,  $A$ 为非奇异矩阵,  $x$ 为精确解,  $\tilde{x}$ 为计算解, 残余向量 $r=b-A\tilde{x}$
- 则近似解的相对误差估计

$$\frac{1}{\text{cond}(A)} \frac{\|r(\tilde{x})\|}{\|b\|} \leq \frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|r(\tilde{x})\|}{\|b\|}$$

- $\text{Cond}(A)$ 越小, 相对误差越小
- 近似解的精度不仅依赖于残余向量 $r$ , 也与矩阵 $A$ 的条件数有关

# 相对误差的事后估计

$$A = \begin{bmatrix} 6 & 13 & -17 \\ 13 & 29 & -38 \\ -17 & -38 & 50 \end{bmatrix} \quad A^{-1} = \begin{bmatrix} 6 & -4 & -1 \\ -4 & 11 & 7 \\ -1 & 7 & 5 \end{bmatrix}$$

$$\text{cond}(A)_{\infty} = \|A\|_{\infty} \|A^{-1}\|_{\infty} = 105 \times 22 = 2310$$

- 假定在求解 $Ax=b$ 的过程中，得到的解满足  $\|r\| \leq 0.001$
- 绝对误差上界  $\|\Delta x\| \leq \|A^{-1}\| \|r\| \leq 22 \times 0.001 = 0.022$
- 若给定 $\|b\|=4$ ，相对误差上界

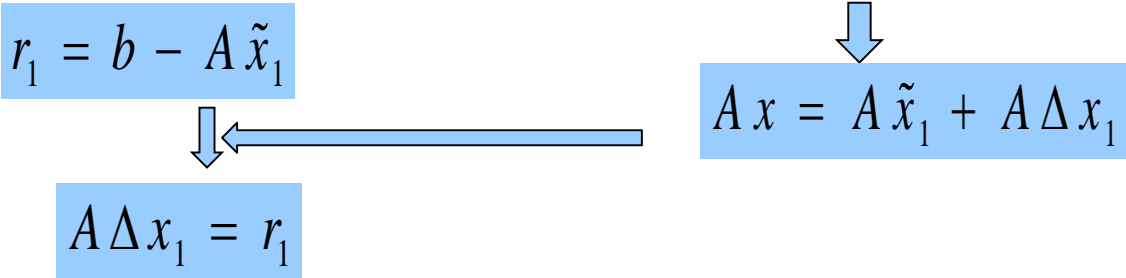
$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|r(\tilde{x})\|}{\|b\|} = 2310 \times \frac{0.001}{4} = 0.5775$$



# 病态方程组的判别

- 当 $A$ 的行列式值相对小，或 $A$ 某些行/列近似线性相关，方程组可能病态
- 若用选主元消去法求解 $Ax=b$ ，在 $A$ 消去中出现小主元，方程组可能病态
- 当 $A$ 元素数量级相差很大且无一定规则，方程组可能病态
- 估计条件数，若条件数较大，则方程组病态

# 迭代求精技术


- 设 $x$ 为精确解,  $\tilde{x}_1$ 为得到的近似解, 则  $x = \tilde{x}_1 + \Delta x_1$
- 残余向量  $r_1 = b - A\tilde{x}_1$   

$$A\Delta x_1 = r_1$$
- 通过求解上述方程, 可以得到修正因子  $\Delta x_1$
- 由于舍入误差的影响, 同样  $\tilde{x}_2 = \tilde{x}_1 + \Delta x_1$  不会是精确解, 可从  $\tilde{x}_2$  出发重复以上步骤
- 对于LU分解, 只需计算残余向量再进行回代, LU分解的目的就是高效求解右边常数向量不同的方程组, 采用迭代求精非常有效
- 当 $Ax=b$ 不过分病态时, 迭代求精是较成功的提高近似解精度的方法

# 本章内容

- 高斯消去法
- LU分解、特殊矩阵和矩阵求逆
- 误差分析、条件数
- 迭代方法

# 迭代法的思想

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 &= b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 &= b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 &= b_3 \end{aligned}$$



$$\begin{aligned} x_1 &= \frac{b_1 - a_{12}x_2 - a_{13}x_3}{a_{11}} \\ x_2 &= \frac{b_2 - a_{21}x_1 - a_{23}x_3}{a_{22}} \\ x_3 &= \frac{b_3 - a_{31}x_1 - a_{32}x_2}{a_{33}} \end{aligned}$$

## First Iteration

$$\begin{aligned} x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\ x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\ x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33} \end{aligned}$$

$$\begin{aligned} x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\ x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\ x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33} \end{aligned}$$

## Second Iteration

$$\begin{aligned} x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\ x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\ x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33} \end{aligned}$$

$$\begin{aligned} x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\ x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\ x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33} \end{aligned}$$

高斯-赛得尔方法  
(异步迭代法)

雅可比方法  
(同步迭代法)

# 迭代法

$$Ax = b \implies x = Gx + f$$

- 任取初始向量  $x^{(0)}$ ，作

$$x^{(1)} = Gx^{(0)} + f$$

$$x^{(k+1)} = Gx^{(k)} + f$$

- 构造向量序列  $\{x^{(k)}\}$  求方程的近似解的方法，称为一阶定常迭代法， $G$ 为该迭代法的迭代矩阵。
- 如果对任意取初始近似  $x^{(0)}$ ，都有  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$ ，称迭代法为**收敛**，否则称迭代法为**发散**。若迭代法收敛，则称  $x^{(k)}$  为第  $k$  步迭代得到方程组的近似解。

# 迭代法

- 问题
  - 构造迭代方法
  - 迭代的收敛性和收敛速度

# 基本迭代方法

$$A = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} - \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \vdots & \ddots & \\ -a_{n1} & -a_{n2} & \cdots & 0 \end{bmatrix} - \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ & 0 & \cdots & -a_{2n} \\ & & \ddots & \vdots \\ & & & 0 \end{bmatrix} = D - L - U$$

- $A$ 分裂为 $A=M-N$
- 分裂阵 $M$ 
  - 可选择非奇异阵
  - $Mx=d$ 易于求解
  - $M$ 选为 $A$ 的某种近似
- $Ax=b \implies Mx=Nx+b \implies x=M^{-1}Nx+M^{-1}b$
- 迭代：
  - $x^{(0)}$ 为初始向量
  - $x^{(k+1)}=M^{-1}Nx^{(k)}+M^{-1}b$
- 选取不同的 $M$ 阵就得到不同迭代法。

# 雅可比(Jacobi)迭代法（同步迭代法）

- 设A为非奇异矩阵，且 $a_{ii} \neq 0$ ，选取  $M=D$  和  $N=D-A=L+U$
- $x^{(k+1)} = Jx^{(k)} + f$        $J = D^{-1}(L+U)$        $f = D^{-1}b$

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \dots \\ b_n \end{bmatrix} \Rightarrow \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \dots & \\ & & & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} = \begin{bmatrix} 0 & -a_{12} & \dots & -a_{1n} \\ -a_{21} & 0 & \dots & -a_{2n} \\ \dots & \dots & \dots & \dots \\ -a_{n1} & -a_{n2} & \dots & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ \dots \\ b_n \end{bmatrix}$$

(1)雅可比迭代法，每迭代一次主要是计算一次矩阵乘向量，即 $Jx^{(k)}$ 。

(2)计算过程中，原始数据A始终不变。

(3)计算中需要两组工作单元来保存 $x^{(k)}$ 及 $x^{(k+1)}$ 。

$$\begin{bmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ \vdots \\ x_n^{(k+1)} \end{bmatrix} = \begin{bmatrix} 0 & -\frac{a_{12}}{a_{11}} & \dots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & \dots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & \dots & \dots & 0 \end{bmatrix} \begin{bmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{bmatrix} + \begin{bmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \vdots \\ \frac{b_n}{a_{nn}} \end{bmatrix}$$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} \right)$$



# 高斯-赛德尔(Gauss-Seidel)迭代法（异步迭代法）

- 选取  $M=D-L$  和  $N=M-A=U$
- $x^{(k+1)}=Gx^{(k)}+f$        $G=(D-L)^{-1}U$        $f=(D-L)^{-1}b$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

(1)G-S迭代法每迭代一次主要是计算一次矩阵乘向量。

(2)计算 $x^{(k+1)}$ 的第 $i$ 个分量 $x_i^{(k+1)}$ 时，利用已计算出的最新分量 $x_j^{(k+1)}(j=1,\dots,i-1)$ ，因此，计算中只需要一组工作单元来保存 $x^{(k)}$ 或 $x^{(k+1)}$ 。

# 迭代终止准则

- 近似相对百分误差

$$|\varepsilon_a|_i = \left| \frac{x_i^{(k+1)} - x_i^{(k)}}{x_i^{(k+1)}} \right| \times 100\%$$

- 对所有的 $i$ ，近似相对百分误差小于预设的 $\varepsilon_s$ 时，迭代终止
- 其他的终止准则  $\|x^{(k+1)} - x^{(k)}\|$

# 迭代法——例

- 求解线性代数方程组

$$\begin{bmatrix} 10 & -2 & -1 \\ -2 & 10 & -1 \\ -1 & -2 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ 15 \\ 10 \end{bmatrix}$$

- Jacobi迭代

$$J = \begin{bmatrix} 0 & 0.2 & 0.1 \\ 0.2 & 0 & 0.1 \\ 0.2 & 0.4 & 0 \end{bmatrix}$$

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 & 0.2 & 0.1 \\ 0.2 & 0 & 0.1 \\ 0.2 & 0.4 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} 0.3 \\ 1.5 \\ 2 \end{bmatrix}$$

$$\begin{cases} x_1^{(k+1)} = 0.2x_2^{(k)} + 0.1x_3^{(k)} + 0.3 \\ x_2^{(k+1)} = 0.2x_1^{(k)} + 0.1x_3^{(k)} + 1.5 \\ x_3^{(k+1)} = 0.2x_1^{(k)} + 0.4x_2^{(k)} + 2 \end{cases}$$

- G-S迭代

$$\begin{cases} x_1^{(k+1)} = 0.2x_2^{(k)} + 0.1x_3^{(k)} + 0.3 \\ x_2^{(k+1)} = 0.2x_1^{(k+1)} + 0.1x_3^{(k)} + 1.5 \\ x_3^{(k+1)} = 0.2x_1^{(k+1)} + 0.1x_2^{(k+1)} + 2 \end{cases}$$

# 迭代法——例

**G-S方法比Jacobi方法收敛快。**

迭代次数	Jacobi方法						G-S方法					
	$x_1$	$ \varepsilon_a _1$	$x_2$	$ \varepsilon_a _2$	$x_3$	$ \varepsilon_a _3$	$x_1$	$ \varepsilon_a _1$	$x_2$	$ \varepsilon_a _2$	$x_3$	$ \varepsilon_a _3$
0	0		0		0		0		0		0	
1	0.3	100	1.5	100	2	100	0.3	100	1.56	100	2.684	100
2	0.8	62.5	1.76	14.7727	2.66	24.812	0.8804	65.9246	1.9445	19.7729	2.9539	9.1362
3	0.918	12.854	1.926	8.6189	2.864	7.1229	0.9843	10.5542	1.9922	2.3975	2.9938	1.3322
4	0.9716	5.5167	1.97	2.2335	2.954	3.0467	0.9997	1.3571	1.9989	0.335	2.9991	0.1796
5	0.9894	1.7991	1.9897	0.9911	2.9823	0.9496	1	0.1879	1.9999	0.0457	2.9999	0.0247
6	0.9962	0.6802	1.9961	0.3202	2.9938	0.3824	1	0.0257	2	0.0063	3	0.0034
7	0.9986	9.2427	1.9986	0.1251	2.9977	0.1305	1	0.0035	2	0.0009	3	0.0005
8	0.9995	0.0892	1.9995	0.0438	2.9992	0.0495						
9	0.9998	0.0324	1.9998	0.0163	2.9997	0.0176						
10	0.9999	0.0118	1.9999	0.0059	2.9999	0.0065						

# 迭代法的收敛性

- $x=Gx+f$        $x^*=Gx^*+f$
- 迭代  $x^{(k+1)}=Gx^{(k)}+f$
- 引入误差向量  $e^{(k)}=x^{(k)}-x^*$
- 误差向量的递推公式:  $e^{(k+1)}=Ge^{(k)}$
- 于是  $e^{(k)}=Ge^{(k-1)}=G^2e^{(k-2)}=\dots=G^ke^{(0)}$  ( $e^{(0)}=x^{(0)}-x^*$ )

$$\|e^{(k)}\| = \|G^k e^{(0)}\| \leq \|G\|^k \|e^{(0)}\| = q^k \|e^{(0)}\|$$

- 定理: 设  $G \in R^{n \times n}$ , 则  $G^k \rightarrow 0$  (零矩阵) (当  $k \rightarrow \infty$  时) 的充要条件为  $G$  所有特征值满足  $|\lambda_i| < 1$  ( $i=1, 2, \dots, n$ ) 或  $G$  的谱半径  $\rho(G) < 1$

# 迭代法的收敛性

- 一阶定常迭代法收敛性的基本定理

设有方程组  $x=Gx+f$ ，有迭代法  $x^{(k+1)}=Gx^{(k)}+f$ ，则对任选初始向量  $x^{(0)}$ ，迭代法收敛的充要条件是  $\rho(G)<1$ 。

- 迭代收敛的充分条件

设有方程组  $x=Gx+f$  及一阶定常迭代法  $x^{(k+1)}=Gx^{(k)}+f$ ，如果有  $G$  的某种范数  $\|G\|_r=q<1$ ，则

- 迭代法收敛；

- 误差估计  $\|x^* - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\| < \frac{1}{1-q} \|x^{(k)} - x^{(k-1)}\|$  事后估计

$$\|x^* - x^{(k)}\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\| \quad \text{事前估计}$$

- 当  $q \approx 1$  时，迭代法收敛缓慢。

$q$  越小收敛速度越快；可以事先估计保证误差  $\|x^* - x^{(k)}\|_\infty < \varepsilon$  所需要的迭代次数。

# 迭代法的收敛性

## 推论:

- Jacobi迭代法收敛的充要条件是 $\rho(J) < 1$  ( $J = D^{-1}(L+U)$ )
- G-S迭代法收敛的充要条件是 $\rho(G) < 1$  ( $G = (D-L)^{-1}U$ )

## 例1:

$$A = \begin{bmatrix} 1 & 0.8 & 0.8 \\ 0.8 & 1 & 0.8 \\ 0.8 & 0.8 & 1 \end{bmatrix}$$

$$J = \begin{bmatrix} 0 & -0.8 & -0.8 \\ -0.8 & 0 & -0.8 \\ -0.8 & -0.8 & 0 \end{bmatrix}$$

$\rho(J) = 1.6 > 1$  Jacobi迭代不收敛

$$G = \begin{bmatrix} 1 & 0 & 0 \\ 0.8 & 1 & 0 \\ 0.8 & 0.8 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 0 & -0.8 & -0.8 \\ 0 & 0 & -0.8 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -0.8 & -0.8 \\ 0 & 0.64 & -0.16 \\ 0 & 0.128 & 0.768 \end{bmatrix}$$

$\rho(G) < 1$  G-S迭代收敛

## 例2:

$$A = \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix}$$

$$J = \begin{bmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{bmatrix}$$

$\rho(J) < 1$  Jacobi迭代收敛

$$G = \begin{bmatrix} 0 & -2 & 2 \\ 0 & 2 & -3 \\ 0 & 0 & 2 \end{bmatrix}$$

$\rho(G) > 1$  G-S迭代不收敛

数值计

对于给定的线性方程组, 用雅可比法和G-S法求解时可能都收敛或都不收敛, 也可能一个收敛另一个不收敛。

# 迭代法的收敛性

- 如果 $A$ 为（按行）严格对角占优阵，则 $Ax=b$ 的Jacobi方法和G-S方法都收敛。
  - 实际上，如果 $A$ 为严格对角占优阵，可以证明， $\|J\|_{\infty} < 1$ 并且 $\|G\|_{\infty} < 1$ ，因此，Jacobi方法和G-S方法都收敛。
  - G-S迭代法比Jacobi迭代法收敛得快
- 如果 $A$ 为对称正定矩阵，G-S迭代收敛。
- 例：判断解 $Ax=b$ 的Jacobi方法和G-S方法的收敛性

$$A = \begin{bmatrix} 10 & -2 & -1 \\ -2 & 10 & -1 \\ -1 & -2 & 5 \end{bmatrix}$$

$$|a_{11}| = 10 > |-2| + |-1|$$

$$|a_{22}| = 10 > |-2| + |-1|$$

$$|a_{33}| = 5 > |-1| + |-2|$$

$A$ 是严格对角占优矩阵，两种方法都收敛



# 迭代法的收敛性

- 例：用G-S方法求解

$$3x_1 + 7x_2 + 13x_3 = 76$$

$$x_1 + 5x_2 + 3x_3 = 28$$

$$12x_1 + 3x_2 - 5x_3 = 1$$

不收敛！

Iteration	$x_1$	$ \varepsilon_a _1$	$x_2$	$ \varepsilon_a _2$	$x_3$	$ \varepsilon_a _3$
1	21.000	110.71	0.80000	100.00	5.0680	98.027
2	-196.15	109.83	14.421	94.453	-462.30	110.96
3	-1995.0	109.90	-116.02	112.43	4718.1	109.80
4	-20149	109.89	1204.6	109.63	-47636	109.90
5	$2.0364 \times 10^5$	109.90	-12140	109.92	$4.8144 \times 10^5$	109.89
6	$-2.0579 \times 10^5$	1.0990	$1.2272 \times 10^5$	109.89	$-4.8653 \times 10^6$	109.89

$$[A] = \begin{bmatrix} 3 & 7 & 13 \\ 1 & 5 & 3 \\ 12 & 3 & -5 \end{bmatrix}$$



$$[A] = \begin{bmatrix} 12 & 3 & -5 \\ 1 & 5 & 3 \\ 3 & 7 & 13 \end{bmatrix}$$

不是所有的矩阵都可以通过重排变为严格对角占优阵

$$x_1 + x_2 + x_3 = 3$$

$$2x_1 + 3x_2 + 4x_3 = 9$$

$$x_1 + 7x_2 + x_3 = 9$$

# 逐次超松弛迭代法(SOR, Successive Over-Relaxation)

$$\tilde{x}_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

G-S方法得到的解

- 高斯-赛得尔方法的基础上进行修改

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega\tilde{x}_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) \quad 0 < \omega < 2, \text{ 称为松弛因子}$$

- $\omega=1$ , SOR方法即为G-S方法
- $0 < \omega < 1$ , 结果为当前迭代结果和上一次迭代结果的加权平均, 称为低松弛方法。用于使得非收敛方程组收敛或者克服振荡加速收敛。
- $1 < \omega < 2$ , 超松弛方法
  - 隐含假设: 新值沿正确方向向真实解移动, 但是移动的速度慢
  - 用于加速已知是收敛的方程组的收敛速度
  - 根据经验确定 $\omega$ 值

# SOR——例

$$\begin{bmatrix} -4 & 1 & 1 & 1 \\ 1 & -4 & 1 & 1 \\ 1 & 1 & -4 & 1 \\ 1 & 1 & 1 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

精确解为 $x^* = [-1 \ -1 \ -1 \ -1]^T$ ，初始向量 $x^{(0)} = [0 \ 0 \ 0 \ 0]^T$

松弛因子	满足 $\ x^{(k)} - x^*\  < 10^{-5}$ 的迭代次数
1.0	22
1.1	17
1.2	12
1.3	11
1.4	14
1.5	17
1.6	23
1.7	33
1.8	53
1.9	107

最佳松弛因子

# SOR——收敛性

- SOR的矩阵形式

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)$$

$$M = (D - \omega L) / \omega$$



$$(D - \omega L)x^{(k+1)} = [(1 - \omega)D + \omega U]x^{(k)} + \omega b$$



$$x^{(k+1)} = G\omega x^{(k)} + f$$

$$G\omega = (D - \omega L)^{-1} [(1 - \omega)D + \omega U]$$

$$f = \omega(D - \omega L)^{-1} b$$

- SOR法收敛的充要条件是  $\rho(G\omega) < 1$
- 如果A为对称正定阵，且  $0 < \omega < 2$ ，则解  $Ax = b$  的SOR法收敛。

# MATLAB中的函数

矩阵分析		线性方程组	
函数	描述	函数	描述
cond	计算矩阵条件数	右除/和左除\	help slash
norm	计算矩阵或向量的范数	lu	lu分解
inv	矩阵求逆	chol	cholesky分解
pinv	求矩阵伪逆		
det	计算行列式的值		
rank	求秩		
eig, eigs	矩阵特征值		

# 第三章 总结——各种方法

方法	稳定性	精度	应用范围	编程难度	备注
图解法	—	差	受限	—	比数值方法耗时
Cramer法则	—	受舍入误差影响	受限	—	方程数多于3个时计算复杂
列主元高斯消去	—	受舍入误差影响	一般，适用于方程组系数矩阵为低阶稠密矩阵、带状矩阵	中等，计算量较小，存储量较大	
LU分解					实现消去法；进行矩阵求逆计算
迭代法 (Jacobi和G-S)	可能不收敛	优秀	收敛时，适用于大型稀疏线性方程组	较简单，计算量有时较大，存储量较小	

# 第三章 总结——重要内容

- 直接法
  - 高斯消去、LU分解
- 迭代
  - Jacobi、Gauss-Seidel、SOR
- 具体算法、问题及改进
- 范数、条件数、病态方程组